


YBS214 - VERİ MADENCİLİĞİ (Data Mining)

Dr.Öğr.Üyesi Günay TEMÜR



DERS BİLGİLERİ - NO

- YBS214 - Veri Madenciliği
- Ders ile ilgili duyurular ve Kaynaklar
 - Telegram
 - <http://www.gunaytemur.com>
 - gunaytemur@duzce.edu.tr
- Değerlendirme
 - Vize %40
 - Final %60
- Devamsızlık
 - %70 Devam etmek zorundasınız 😊



Hafta	Konu	Alt Başlıklar	Uygulama / Kod İçeriği	Kazanım
1	Veri Madenciliğine Giriş	CRISP-DM, Veri Türleri, ML vs DM	Python ortam kurulumu, örnek dataset inceleme	Veri madenciliği sürecini kavrar
2	Veri Ön İşleme	Missing value, Outlier, Normalizasyon	Pandas ile veri temizleme	Ham veriyi analiz edilebilir hale getirir
3	Keşifsel Veri Analizi (EDA)	Korelasyon, Histogram, Feature dağılımı	Seaborn görselleştirme	Veriyi yorumlamayı öğrenir
4	Karar Ağaçları	Entropy, Gini, Overfitting	sklearn DecisionTree	Temel sınıflandırma uygular
5	Random Forest & KNN	Ensemble mantığı, Distance ölçütleri	RandomForest, KNN karşılaştırması	Model performansını kıyaslar
6	Kümeleme (Clustering)	K-Means, Elbow yöntemi	Müşteri segmentasyonu uygulaması	Denetimsiz öğrenme uygular
7	Birliktelik Kuralları	Support, Confidence, Lift	Apriori ile Market Basket analizi	İlişkisel örüntü çıkarır
8	VİZE			
9	Boyut İndirgeme	PCA, Curse of Dimensionality	PCA görselleştirme	Veri boyutunu optimize eder
10	Model Performansı	Accuracy, Precision, Recall, ROC	Cross validation uygulaması	Model başarımını yorumlar
11	Büyük Veri Kavramı	5V, Structured vs Unstructured	Büyük veri mimarileri analizi	Büyük veri mantığını kavrar
12	Hadoop Ekosistemi	HDFS, MapReduce, NameNode	Mimari diyagram inceleme	Dağıtık veri işleme yapısını öğrenir
13	Apache Spark (Local Mode)	RDD, DataFrame, In-memory processing	PySpark ile 5M satır veri işleme	Paralel veri işleme uygular
14	GPU Destekli ML	CPU vs GPU, CUDA mantığı	XGBoost GPU hız karşılaştırması	Büyük veri + GPU entegrasyonunu kavrar

VERİ MADENCİLİĞİNE GİRİŞ


- **TANIM_1** : Büyük miktardaki veriler içerisinde önemli olanlarını bulup çıkarmaya Veri Madenciliği denir.
- **TANIM_2** : Veri Madenciliği (Data Mining): Büyük miktarda veri içinden, gelecekle ilgili tahmin yapmamızı sağlayacak bağıntı ve kuralların aranmasıdır. (Knowledge Discovery in Databases).
- **Tanım_3** : Kurumlardaki büyük ölçekli olarak tanımlanan ve milyonlarca veriye sahip yazılım sistemlerinden, ihtiyacı karşılayacak değerli verilerin elde edilmesi işlemine Veri Madenciliği denilmektedir.
- **Tanım_4** : Büyük ölçekli veriler arasından değeri olan bir bilgiyi elde etme işidir.

VERİ MADENCİLİĞİNE GİRİŞ


- **Sonuç olarak;** Teknolojinin gelişmesi ve yaygınlaşması ile daha önce fiziksel olarak yapılan birçok iş ve işlem artık bilgisayardan, cep telefonundan ya da tabletten yapılıyor. Sensörlerden alınan bilgiler, güvenlik amaçlı kullanılan retina ve parmak izi verileri, meteorolojik ve jeofizik veriler, tıbbi kayıtlar, banka ödemeleri, alışveriş, hastane randevusu alma ve daha birçok iş, telefonun birkaç tuşuna basarak gerçekleştirilebilmektedir. Bu durum dijital veri toplamanın ve saklamanın ne kadar yaygın olduğunu göstermektedir.
- Telefon ya da bilgisayar ile internet üzerinden yapılan her işlem sonucunda, veriler ilgili veri tabanlarında birikmektedirler.
- İşletmelerin sunucularında biriken bu verilerin toplanması, analiz edilmesi ve aralarından “İşe yarar” olanların ayıklanması işine “Veri madenciliği” denilmektedir.

ARTAN VERİ BOYUTU

Volume of data created and replicated worldwide (source: IDC)



TAHMİNİ VERİ BOYUTU



VERİ BOYUTU

1	geopbyte
1024	Brontobyte
1048576	yottabyte
1073741824	zettabyte
1099511627776	eksabyte
1125899906842620	petabyte
1152921504606850000	terabyte
1180591620717410000000	gigabyte
12089258196146300000000000	megabyte
123794003928538000000000000000	kilobyte
1267650600228230000000000000000000	byte
12980742146337100000000000000000000000	bit

VERİ MADENCİLİĞİ TANIMLARI

- Bu tanımlamalardan da anlaşıldığı üzere veriler arasındaki ilişkileri ortaya koymak ve gerektiğinde ileriye yönelik tahminlerde bulunmak veri madenciliği çalışmaları sayesinde mümkün olmaktadır.
- Bunun anlamı, veri madenciliği bir kurumda üretilen tüm verilerin belirli yöntemler kullanarak var olan ya da gelecekte ortaya çıkabilecek gizli bilgiyi ortaya çıkarma süreci olarak değerlendirilmesidir. Bu açıdan bakıldığında veri madenciliği işinin kurumların Karar Destek Sistemleri için önemli bir yere sahip olduğu söylenebilir.

VERİ MADENCİLİĞİ İLE İLİŞKİLİ DİĞER DİSİPLİNLER

- Veri madenciliği disiplinlerarası bir çalışmadır. İstatistik, veritabanı teknolojileri, makine öğrenmesi, yapay zeka ve görselleştirme gibi bir çok farklı disiplin bünyesinde gelişen yöntemleri kullanır.



VERİ MADENCİLİĞİNİN TARİHÇESİ

1950'ler

ilk bilgisayarlar
(Sayımlar için bilgisayarlar kullanılıyor)

1970'ler

İlişkisel veri modeli İlişkisel VTYS uygulamaları

1990'lar

Günlük işlemlerden derlenen büyük miktarda verinin nasıl değerlendirilebileceği sorgulanmaya başlıyor. Bu noktada bahsedilmesi gereken birkaç önemli olay söz konusu: 1989, Veri Tabanlarında Bilgi Keşfi Çalışmaları

1960'lar

Veri kolleksiyonları Veritabanı oluşumu
(Hiyerarşik ve ağ modelleri)

1980'ler

İlişkisel VTYS yaygınlaşıyor Uygulamaya yönelik VTYS (Mekansal, Bilimsel, Mühendislik, vs.)

1991,

Knowledge Discovery in Real Databases: A Report on the IJCAI-89 Workshop' makalenin KDD ile ilgili temel tanım ve kavramları ortaya koyması

1992,

Veri Madenciliği konusunda ilk yazılımın geliştirilmesi

VERİ MADENCİLİĞİNİN TARİHÇESİ

- Veri madenciliği kavramı 1990'lı yılların başında akademik olarak gelişmeye başlamıştır ve bu yıllarda IBM ve SAS gibi firmalar ticari veri madenciliği yazılımlarını geliştirmiştir.
- 1992 yılında veri madenciliği alanında geliştirilen ilk yazılımlardan biri IBM'in Intelligent Miner yazılımıdır.
- İlk Veri Madenciliği Yazılımları (1990'lar)

1. IBM Intelligent Miner (1996)

1. IBM tarafından geliştirilen bu yazılım, büyük ölçekli veri analizi ve madencilik işlemleri için tasarlandı.
2. Karar ağaçları, sinir ağları ve istatistiksel analizler yapabiliyordu.

2. SAS (Statistical Analysis System) Enterprise Miner (1998)

1. SAS tarafından geliştirilen bu yazılım, özellikle iş analitiği ve veri madenciliği süreçlerini optimize etmek için kullanıldı.

3. WEKA (1993)

1. Waikato Üniversitesi tarafından geliştirilen açık kaynaklı bir veri madenciliği yazılımıdır.
2. Günümüzde bile makine öğrenimi ve veri madenciliği eğitimlerinde sıkça kullanılmaktadır.

VERİ MADENCİLİĞİNİN TARİHÇESİ

1995,

1. Uluslararası Bilgi Keşfi ve Veri
Madenciliği Konferansı'nın (KDD-95)
açılış konuşması

2000'ler

Veri Ambarları,
Veri Madenciliğinin yaygınlaşması.

VERİ MADENCİLİĞİNİN TARİHÇESİ

Veri Ambarlarının Tanımı

- **Veri ambarı**, farklı kaynaklardan gelen büyük hacimli verileri **entegrasyon, analiz ve raporlama** için bir araya getiren sistemdir.
- İşletmeler, karar alma süreçlerini iyileştirmek için **veri ambarlarını** kullanır.
- **Online Analytical Processing (OLAP)** sistemleriyle veri analizi yapmaya uygundur.

Veri Ambarlarının Özellikleri

- **Konu Odaklıdır** → Belirli bir iş alanına (örneğin, satış, finans, müşteri analizi) odaklanır.
- **Bütünleşiktir** → Farklı sistemlerden gelen verileri tek bir yapıda birleştirir.
- **Zamana Bağlıdır** → Veriler zaman içinde değişimi izlemek için saklanır.
- **Değişmezdir** → Veri ambarına kaydedilen veriler güncellenmez veya silinmez, sadece ekleme yapılır.

VERİ MADENCİLİĞİNİN TARİHÇESİ

Veri Ambarlarının Kullanım Alanları

- **İş Zekası (BI):** Şirketlerin performanslarını analiz etmeleri için kullanılır.
- **Finans ve Bankacılık:** Müşteri davranışlarını anlamak ve risk yönetimi için kullanılır.
- **E-Ticaret ve Perakende:** Müşteri trendlerini ve satışları analiz etmek için kullanılır.
- **Sağlık Sektörü:** Hastane kayıtlarını analiz etmek ve sağlık hizmetlerini iyileştirmek için kullanılır.

Veri Ambarı Örnekleri

- **Amazon Redshift** → AWS tabanlı büyük ölçekli veri ambarı.
- **Google BigQuery** → Büyük veri analizi için Google'ın bulut veri ambarı.
- **Snowflake** → Modern bulut tabanlı veri ambarı çözümü.
- **Microsoft Azure Synapse** → Microsoft'un büyük veri analiz platformu.


BİLGİ KEŞFİ

- Teoride veri madenciliği, bilgi keşfi işleminin aşamalarından biridir.
- Pratikte veri madenciliği ve bilgi keşfi eş anlamlı olarak kullanılır.
- Veri madenciliği teknikleri veriyi belli bir modele uydurur.
 - veri içindeki örüntüleri bulur
 - örüntü: veri içindeki herhangi bir yapı
- Sorgulama ya da basit istatistik yöntemler veri madenciliği değildir.

BİLGİ KEŞFİ

- Büyük veri kaynaklarından yararlı ve ilginç bilgiyi bulmak
- Bulunan bilgi
 - gizli,
 - önemli,
 - önceden bilinmeyen,
 - yararlı olmalı.

BİLGİ KEŞFİ



BİLGİ KEŞFİNİN AŞAMALARI

- Veri Temizleme : Gürültülü ve tutarsız verileri çıkarmak
- Veri Bütünleştirme : Birçok data kaynağını birleştirebilmek
- Veri Seçme : Yapılacak olan analiz ile ilgili olan verileri belirlemek
- Veri Dönüşümü : Verinin veri madenciliği yöntemine göre hale dönüşümünü gerçekleştirmek
- Veri Madenciliği : Verilerdeki örüntülerin belirlenmesi için veri madenciliği yöntemlerinin uygulanması
- Örüntü Değerlendirme : Bazı ölçütlere göre elde edilmiş ilginç örüntüleri bulmak ve değerlendirmek
- Bilgi Sunumu : Elde edilen bilgilerin kullanıcılara sunumu

VERİ TABANLARINDA BİLGİ KEŞFİ

- Veri Tabanlarında Bilgi Keşfi, veriden faydalı bilginin keşfedilmesi sürecinin tamamına atıfta bulunmakta ve veri madenciliği bu sürecin bir adımına karşılık gelmektedir.

VERİ MADENCİLİĞİNİN CEVAPLAYABİLECEĞİ SORULAR NELERDİR?

- Bilinmeyen bilgiyi ortaya çıkarmak için çalışır
- Bu sene potansiyel en iyi 10 müşterimiz kimler olacaktır sorusuna cevap arar
- Gelecek 5 sene şirketimiz hangi alanda büyümeli/büyüyebilir
- Bu hastanın hastalığı ne olabilir
- Kanseri erken teşhis edebilir miyim

VERİ MADENCİLİĞİNİN UYGULAMA ALANLARI

- Finans Sektörü
- Haberleşme Sektörü
- Sağlık Sektörü
- Devlet Uygulamaları

Büyük hacimde veri olan her yerde veri madenciliği kullanılabilir.

VERİ MADENCİLİĞİNİN UYGULAMA ALANLARI

Veritabanı analizi ve karar verme desteği

- Pazar araştırması
 - Hedef Pazar, müşteriler arası benzerliklerin saptanması, sepet analizi, çapraz pazar incelemesi
- Risk analizi
 - Kalite kontrolü, rekabet analizi, öngörü
- Sahtekarlıkların saptanması
- Diğer Uygulamalar
 - Belgeler arası benzerlik (haber kümeleri, e-posta)
 - Sorgulama sonuçları

VERİ MADENCİLİĞİNİN UYGULAMA ALANLARI

Bilim	İş Hayatı	Web	Devlet
• Astronomi • Biyoinformatik • İlaç keşfi	• Reklam • CRM (Müşteri İlişkileri Yönetimi) ve Müşteri Modelleme • E-ticaret • Yatırım değerlendirme ve karşılaştırma • Sağlık • Üretim • Spor/eğlence • Telekom (telefon ve iletişim) • Hedef pazarlama	• Metin Madenciliği (haber grubu, email, dokümanlar) • Web analizi • Arama motorları	• Kanun Yaptırımı • Vergi Kaçakçılarının Profilinin Çıkarılması

VERİ MADENCİLİĞİNİN UYGULAMA ALANLARI


- Hangi promosyonu ne zaman uygulamalıyım?
- Hangi müşteri aldığı krediyi geri ödemeyebilir?
- Bir müşteriye ne kadar kredi verilebilir?
- Sahtekarlık olabilecek davranışlar hangileridir?
- Hangi müşteriler yakın zamanda kaybedilebilir?
- Hangi müşterilere promosyon yapmalıyım?
- Hangi yatırım araçlarına yatırım yapmalıyım?

VERİ KAYNAKLARI

- Veri dosyaları
- Veritabanı kaynaklı veri kümeleri
 - ilişkisel veritabanları, veri ambarları
- Gelişmiş veri kümeleri
 - duraksız veri (data stream), algılayıcı verileri (sensor data)
 - zaman serileri, sıralı diziler (biyolojik veriler)
 - çizgeler, sosyal ağ (social networks) verileri
 - konumsal veriler (spatial data)
 - çoklu ortam veritabanları (multimedia databases)
 - nesneye dayalı veritabanları
 - WWW

VERİ MADENCİLİĞİ ALGORİTMALARI

- amaç: veriyi belli bir modele uydurmak
 - tanımlayıcı
 - En iyi müşterilerim kimler?
 - Hangi ürünler birlikte satılıyor?
 - Hangi müşteri gruplarının alışveriş alışkanlıkları benzer?
 - kestirime dayalı
 - Kredi başvurularını risk gruplarına ayırma
 - Şirketle çalışmayı bırakacak müşterileri öngörme
 - Borsa tahmini
- seçim: veriye uyan en iyi modeli seçmek için kullanılan kriter
- arama: veri üzerinde arama yapmak için kullanılan teknik



VERİ MADENCİLİĞİ İŞLEVLERİ

- Sınıflandırma (Classification): Veriyi önceden belirlenmiş sınıflardan birine dahil eder.
 - Danışmanlı (Gözetimli) öğrenme
 - Örüntü tanıma
 - Kestirim
- Eğri uydurma (Regression): Veriyi gerçel değerli bir fonksiyona dönüştürür.
- Zaman serileri inceleme (Time Series Analysis): Zaman içinde değişen verinin değerini öngörür.
- İstisna Analizi (Outlier Analysis): Verinin geneline uymayan nesneleri belirleme

VERİ MADENCİLİĞİ İŞLEVLERİ

- Kümeleme (Clustering): Benzer verileri aynı grupta toplama
 - Danışmansız (Gözetimsiz) öğrenme
- Özetleme (Summarization): Veriyi alt gruplara ayırır. Her alt grubu temsil edecek özellikler bulur.
 - Genelleştirme (Generalization)
 - Nitelendirme (Characterization)
- İlişkilendirme kuralları (Association Rules)
 - Veriler arasındaki ilişkiyi belirler
- Sıralı dizileri bulma (Sequence Discovery): Veri içinde sıralı örüntüler bulmak için kullanılır.

VERİ MADENCİLİĞİNDE TEMEL KAVRAMLAR

- Veri (Data)
- Enformasyon(Information)
- Bilgi (Knowledge)
- Bilgelik (Wisdom)

VERİ (DATA)

- Veri, oldukça esnek bir yapıdadır. Temel olarak varlığı bilinen, işlenmemiş, ham haldeki kayıtlar olarak adlandırılırlar. Bu kayıtlar ilişkilendirilmemiş, düzenlenmemiş yani anlamlandırılmamışlardır. Ancak bu durum her zaman geçerli değildir. İşlenerek farklı bir boyut kazanan bir veri, daha sonra bu haliyle kullanılmak üzere kayıt altına alındığında, farklı bir amaç için veri halini koruyacaktır. Bu konuyu daha iyi açıklayabilmek için enformasyon kavramını incelemek gerekmektedir.
- a. Bir araştırmanın, bir tartışmanın, bir muhakemenin temeli olan ana öge.
- b. Bir sanat eserine veya bir edebî esere temel olan ana ilkeler: "Bir romanın verileri."
- c . Bilgi, data.
- d. Matematik: Bir problemde bilinen, belirtilmiş anlatımlardan bilinmeyeni bulmaya yarayan şey.
- e. Bilişim: Olgu, kavram veya komutların, iletişim, yorum ve işlem için elverişli biçimli gösterimi.

ENFORMASYON (INFORMATION)

- Enformasyon, veri kavramının tanımından yola çıkıldığında, adreslemedeki ikinci safhadır. Yani verilerin ilişkilendirilmiş, düzenlenmiş, anlamlandırılmış, işlenmiş halidir. Bu haliyle enformasyon, potansiyel olarak içinde bilgi barındıran bir veri halindedir.
- Belli bir alanda ve belli bir toplumda bilgi ve haberlerin yayılmasına olanak sağlayan araçların tümüne verilen isimdir.
- Enformasyon, genel olarak insanın dış dünyayla ilişkisinde, belirsizlik düzeyini azaltan her tür uyaran şeklinde tanımlanabilir. Daha özel olarak ise, formatlanmış ve yapılandırılmış veriler bütünü olarak tanımlanabilir.
- Yaygın anlamda enformasyon terimi, "haber" (ing. news, alm. nachricht) veya mesaj terimiyle eşanlamlıdır.
- Veriler enformasyona dönüştürülerek kullanışlı hale getirilirler. Bu yönüyle enformasyon anlam katılmış verilerdir.


BİLGİ (KNOWLEDGE)

- Bilgi, bu süreçteki üçüncü aşamadır. Enformasyonun, bilgiye dönüşmesi, bireyin onu algılaması, özümsemesi ve sonuç çıkarmasıyla gerçekleşir. Dolayısıyla bireyin algılama yeteneği, yaratıcılık, deneyim gibi kişisel nitelikleri de bu süreci doğrudan etkilemektedir.
- «İnsan aklının erebileceği olgu, gerçek ve ilkeler bütünü, malumat» olarak sözlüğümüzde tanımlanan bilgi, bilişim dilinde kurallardan yararlanarak kişinin veriye yönelttiği anlam demektir.
- Felsefi olarak ise insanların maddi ve toplumsal anlaksal etkinliğinin ürünü olarak tanımlanmaktadır.
- Enformasyonun daha yüksek biçimi olarak bilginin tüm modelleri altında yatan, bilginin ham maddelerinden onlara anlam eklenerek ortaya çıkarılması gerektiği düşüncesidir.
- Bilgiden, farklı enformasyon parçacıkları arasındaki ilişkiler anlaşılmalıdır. Örneğin bir kişiyi sadece bir T.C kimlik numarasının temsil edebileceği bilgisine sahip olunmalıdır.

BİLGELİK (WISDOM)

- Bilgelik ulaşılmaya çalışılan noktadır ve bu kavramların zirvesinde yer alır. Bilgilerin kişi tarafından toplanıp bir sentez haline getirilmesiyle ortaya çıkan bir olgudur. Yetenek, tecrübe gibi kişisel nitelikler birer bilgelik elemanıdır.
- Bilgelik bilginin teferruatlı ve hassas kullanımını gerektirir.
- Neyin bilindiğinin (bilgi) ve en iyinin ne olduğunun (sosyal ve etnik faktörler) dikkate alınarak en uygun davranışın sergilenmesi demektir. Belirli bir alanı veya alanları anlamak için daha geniş ve genelleştirilmiş kuralları ve şemaları temsil etmesiyle bilgiden ayrılır.
- Bilgelik karar alma ve kararın uygulanması sırasında tecrübe edilir.

VERİ DEN BİLGİYE



BİTTİ 😊