

VERİ, VERİ ÖNİŞLEME

Dr. Günay TEMÜR

Veri Nedir?

- Nesneler ve nesnelerin niteliklerinden oluşan küme
 - *kayıt (record), varlık (entity), örnek (sample, instance) nesne için kullanılabilir.*
- Nitelik (attribute) bir nesnenin (object) bir özelliğidir.
 - *bir insanın yaşı, ortamın sıcaklığı...*
 - *boyut (dimension), özellik (feature, characteristic) olarak da kullanılır.*
- Nitelikler ve bu niteliklere ait değerler bir nesneyi oluşturur.

Nitelik (Attributes)			
Id	cinsiyet	Medeni Durum	Yıllık Gelir
1	E	Evli	125K
2	K	Bekar	80K
3	K	Evli	50K
4	E	Bekar	60K
5	E	Evli	70K
6	E	Bekar	30K
7	K	Evli	40K
8	E	Evli	100K
9	K	Evli	80K

Nesne (objects)

Değer Kümeleri

- Nitelik için saptanmış sayılar veya semboller
- Nitelik & Değer Kümeleri
 - *aynı nitelik farklı değer kümelerinden değer alabilir*
 - ağırlık: kg, lb(libre, ağırlık ölçüsü)
 - *farklı nitelikler aynı değer kümesinden değer alabilirler*
 - ID, yaş: her ikisi de sayısal

İstatistiksel Veri Türleri

- **1- Nümerik Veriler :** Sayısal-Nümerik-Nicel veriler de denmektedir. Boy, Yaş gibi süreklilik arz eden değerler Nümerik verilerdir. “Daha fazla” ifadesi ile kullanılabilirler. Sürekli ve süreksiz olarak iki başlıkta ele alınabilir:
 - a) *Sürekli Nümerik Veriler: Yaş, Sıcaklık*
 - b) *Aralıklı Nümerik Veriler (Interval): Çocuk Sayısı, Kaza Sayısı*
- **2-Nominal Veriler :** Kategorik bir veri çeşididir. “Daha fazla” ifadesi ile kullanılmazlar. İkiye ayrılır:
 - a) *Binary Veriler: Var-Yok, Kadın-Erkek, Hasta-Sağlıklı*
 - b) *İkiden Çok Kategorili: Renk-Şehir, İsim, Forma Numarası Örneğin forma numarası oyuncunun seviyesi ile ilgili bir bilgi içermez.*

İstatistiksel Veri Türleri

- **3-Ordinal Veriler :** Ordinal veriler de yine kategorik veri türündendir. Fakat değerleri arasında sıralı bir ilişki bulunmaktadır. “Daha fazla” ifadesi ile kullanılabilirler ancak ne kadar daha fazla olduğunun ölçüsünü veremezler. Örneğin: Eğitim Düzeyi, Sosyoekonomik ölçek skorları gibi. Nominal veriler, ordinal verilere göre daha az bilgi taşırlar.
- **4-Ratio Veriler :** Nümerik verilere benzerler. Oran verilebilir veri türlerine Ratio veriler denir. !!! Kelvin derece ratio türünden bir değişken iken, santigrat ise nümerik veri türüne örnek olarak verilebilir. Çünkü 100 santigrat derece, 50 santrigat derecenin iki katı denilemez ama derece kelve çevrilirse 60 kelvin 30 kelvinin 2 misli sıcak denilebilir.

Nitelik Türleri

- Belli aralıkta yer alan değişkenler (interval)
 - *sıcaklık, tarih*
- İkili değişkenler (binary)
 - *cinsiyet*
- Ayırık ve sıralı değişkenler (nominal, ordinal, ratio scaled)
 - *göz rengi, posta kodu*

Problem

- Gerçek uygulamalarda toplanan veri genellikle kirlidir.
 - *eksik: bazı nitelik değerleri bazı nesneler için girilmemiş, veri madenciliği uygulaması için gerekli bir nitelik kaydedilmemiş*
 - *meslek = “ ”*
 - *gürültülü: hatalar var*
 - *maaş= “-10”*
 - *tutarsız: nitelik değerleri veya nitelik isimleri uyumsuz*
 - *yaş= “35”, d.tarihi: “03/10/2004”*
 - *önceki oylama değerleri: “1,2,3”, yeni oylama değerleri: “A,B,C”*
 - *bir kaynakta nitelik değeri ‘ad’, diğerinde ‘isim*

Verinin Problem Nedenleri

- Eksik veri kayıtlarının nedenleri
 - *Veri toplandığı sırada bir nitelik değerinin elde edilememesi, bilinmemesi*
 - *Veri toplandığı sırada bazı niteliklerin gerekliliğinin görülememesi*
 - *İnsan, yazılım ya da donanım problemleri*
- Gürültülü (hatalı) veri kayıtlarının nedenleri
 - *Hatalı veri toplama gereçleri*
 - *İnsan, yazılım ya da donanım problemleri*
 - *Veri iletimi sırasında problemler*
- Tutarsız veri kayıtlarının nedenleri
 - *Verinin farklı veri kaynaklarında tutulması*
 - *İşlevsel bağımlılık kurallarına uyulmaması*

Sonuç

- Veri genellikle güvenilmezdir
 - *O ZAMAN NE YAPIYORUZ -->*

Veri Önışleme

- Veri temizleme
 - *Eksik nitelik değęerlerini tamamlama, hatalı veriyi düzeltme, aykırılıkları saptama ve temizleme, tutarsızlıkları giderme*
- Veri birleřtirme
 - *Farklı veri kaynağındaki verileri birleřtirme*
- Veri dönüşümü
 - *Normalizasyon*
 - *Encoding*

Veriyi Tanımlayıcı Özellikler

- Amaç: Veriyi daha iyi anlamak
 - *Merkezi eğilim (central tendency), varyasyon, yayılma, dağılım.*
- Verinin dağılım özellikleri
 - *Ortanca, en büyük, en küçük, sıklık derecesi.*
- Sayısal nitelikler -> sıralanabilir değerler
 - *verinin dağılımı*
 - *kutu grafiği çizimi ve sıklık derecesi incelemesi*

Merkezi Eğilimi Ölçme

- Ortalama
 - *Genel olarak ağırlıklı ortalama*
- Ortanca (Median)
 - *Veri sayısına göre; veri tek ise orta değer çift ise ortadaki iki değer.*
- Mod (Frekans)
 - *Veri içinde en sık görülen değer*

- Veri temizleme
- Veri birleştirme
- Veri dönüşümü

Veri Temizleme

- Gerçek uygulamalarda veri eksik, gürültülü veya tutarsız olabilir.
- Veri temizleme işlemleri
 - *Eksik nitelik değerlerini tamamlama*
 - *Aykırılıkların bulunması ve gürültülü verinin düzeltilmesi*
 - *Tutarsızlıkların giderilmesi*

Eksik Veri

- Eksik nitelik değerleri olan veri kayıtlarını kullanma
- Eksik nitelik değerlerini elle doldur ☺ ?
 - *Eksik nitelik değerleri için global bir değişken kullan (Null, Unknow,...)*

Oyuncu	Takım	Maaş (Önce)
John	A Takımı	50000
Mike	A Takımı	NaN
Alex	A Takımı	54000
Sara	B Takımı	45000
Emma	B Takımı	NaN

Eksik Veri

- Eksik nitelik değerleri olan veri kayıtlarını kullanma
- Eksik nitelik değerlerini elle doldur
 - *Eksik nitelik değerlerini o niteliğin ortalama değeri ile doldur*

Oyuncu	Takım	Maaş (Önce)	Maaş (Sonra - Genel Ortalama ile)
John	A Takımı	50000	50000
Mike	A Takımı	NaN	49666.67
Alex	A Takımı	54000	54000
Sara	B Takımı	45000	45000
Emma	B Takımı	NaN	49666.67

Eksik Veri

- Eksik nitelik değerleri olan veri kayıtlarını kullanma
- Eksik nitelik değerlerini elle doldur
 - *Aynı sınıfa ait kayıtların nitelik değerlerinin ortalaması ile doldur*

Oyuncu	Takım	Maaş (Önce)	Maaş (Sonra - Sınıf Ortalaması ile)
John	A Takımı	50000	50000
Mike	A Takımı	NaN	52000
Alex	A Takımı	54000	54000
Sara	B Takımı	45000	45000
Emma	B Takımı	NaN	45000

Eksik Veri

- Eksik nitelik değerleri olan veri kayıtlarını kullanma
- Eksik nitelik değerlerini elle doldur
 - *Olasılığı en fazla olan nitelik değeriyle doldur*

Oyuncu	Takım
John	A
Mike	A
Sara	B
Alex	A
Emma	NaN



Oyuncu	Takım (Sonra)
John	A
Mike	A
Sara	B
Alex	A
Emma	A

Örnek Uygulama

Python: Hangi Kod Ne Yapıyor?

Kod Parçası	Ne Yapıyor?
<code>df.isnull().sum()</code>	Eksik verileri tespit eder
<code>fillna("Unknown")</code>	Eksik verileri "Unknown" ile doldurur
<code>fillna(df[col].mean())</code>	Sayısal eksik verileri ortalama ile doldurur
<code>groupby("Class").transform(lambda x: x.fillna(x.mean()))</code>	Aynı sınıftaki verilerin ortalaması ile doldurur
<code>fillna(df[col].mode()[0])</code>	Eksik verileri en sık tekrar eden değer ile doldurur

Örnek Uygulama

Python: Hangi Kod Ne Yapıyor?

Kod	Ne Yapar?	Nerede Kullanılır?	Açıklama
<code>df.isnull()</code>	Eksik değerleri True/False gösterir	Kontrol	Hangi hücreler boş görmemizi sağlar
<code>df.isnull().sum()</code>	Sütun bazında eksik değer sayısı	Kontrol	Kaç eksik var öğreniriz
<code>df["col"].mean()</code>	Ortalama hesaplar	Sayısal	Eksik doldurma öncesi ortalama bulur
<code>df["col"].median()</code>	Medyan hesaplar	Sayısal	Aykırı değer varsa tercih edilir
<code>df["col"].mode()</code>	En sık değer	Kategorik	Mode değeri döndürür
<code>df["col"].fillna(value)</code>	NaN değerleri verilen değerle doldurur	Genel	Manuel doldurma
<code>df["col"].fillna(df["col"].mean())</code>	Ortalama ile doldurur	Sayısal	En yaygın yöntem
<code>df["col"].fillna(df["col"].median())</code>	Medyan ile doldurur	Sayısal	Outlier varsa daha doğru
<code>df["col"].fillna(df["col"].mode()[0])</code>	Mode ile doldurur	Kategorik	En sık görülen değer
<code>df.groupby("Sinif")["col"].transform(lambda x: x.fillna(x.mean()))</code>	Sınıf ortalaması ile doldurur	Denetimli veri	Class-based imputation
<code>df.dropna()</code>	Eksik satırları siler	Temizleme	Veri kaybı olabilir
<code>df.dropna(axis=1)</code>	Eksik sütunları siler	Temizleme	Özellik kaybı olabilir

Örnek Kod Parçaları ve Açıklamaları

◆ 1 Ortalama ile doldurma

python

```
df["Maas"] = df["Maas"].fillna(df["Maas"].mean())
```

👉 Maas sütunundaki boş değerleri ortalama ile doldurur.

◆ 2 Mode ile doldurma

python

```
df["Takim"] = df["Takim"].fillna(df["Takim"].mode()[0])
```

👉 Takım sütunundaki eksikleri en sık görülen değerle doldurur.

◆ 3 Sınıf ortalaması ile doldurma

python

```
df["Maas"] = df.groupby("Takim")["Maas"].transform(  
    lambda x: x.fillna(x.mean())  
)
```

👉 Her takım kendi ortalamasına göre doldurulur.

◆ 4 Eksik değer sayısını görmek

python

```
df.isnull().sum()
```

👉 Hangi sütunda kaç eksik var gösterir.

Gürültülü Veri

- Ölçülen bir değerdeki hata
- Yanlış nitelik değerleri
 - *hatalı veri toplama gereçleri*
 - *veri girişi problemleri*
 - *veri iletimi problemleri*
 - *teknolojik kısıtlar*
 - *nitelik isimlerinde tutarsızlık*

Gürültü Temizleme Yöntemleri ve Kullanım Alanları

- Aşağıdaki yöntemler, verideki **gürültüyü temizlemek ve analizleri daha güvenilir hale getirmek** için yaygın olarak kullanılır.

Yöntem	Tanım	Kullanım Alanları
Hareketli Ortalama	Veri noktalarının belirli bir pencere içinde ortalamasını alarak dalgalanmaları yumuşatır.	Finansal veri analizi, sensör verileri, trend analizi
Bölmeleme (Binning)	Veriyi belirli aralıklara bölerek gürültüyü azaltır.	Kategorik veri analizi, veri madenciliği
Eğri Uydurma (Curve Fitting)	Veri setine en uygun matematiksel fonksiyonu bulur.	Fiziksel ölçümler, ekonomi, sinyal işleme

Hareketli Ortalama (Moving Average) Sonuçları ve Açıklamalar

- Basit Hareketli Ortalama (SMA - Simple Moving Average)
 - *Tüm değerler eşit ağırlıklıdır.*
 - *Yukarıda gösterdiğimiz standart hareketli ortalamadır.*
- Ağırlıklı Hareketli Ortalama (WMA - Weighted Moving Average)
 - *En yeni verilere daha fazla ağırlık verir.*
 - *Sonraki veriler önceki verilere göre daha önemli kabul edilir.*
- Üstel Hareketli Ortalama (EMA - Exponential Moving Average)
 - *Önceki verilere üstel olarak azalan bir ağırlık verir.*
 - *Özellikle finansal zaman serilerinde (borsa, kripto) sıklıkla kullanılır.*
- Hareketli Ortalama (MA), verilerdeki dalgalanmaları azaltarak daha düzgün bir trend yakalamak için kullanılan bir yöntemdir.
- Zaman serilerinde kısa vadeli dalgalanmaları yumuşatarak genel eğilimleri belirginleştirmek için sıkça kullanılır

Hareketli Ortalama Formülü

Bir veri noktası için **pencere boyutu (n)** belirlenir ve o pencere içindeki değerlerin ortalaması alınır.

$$MA_t = \frac{X_t + X_{t-1} + X_{t-2} + \dots + X_{t-n+1}}{n}$$

Burada:

- $MA_t \rightarrow t$ anındaki hareketli ortalama değeri
- $X_t \rightarrow t$ anındaki veri noktası
- $n \rightarrow$ Hareketli ortalama için kullanılan pencere boyutu

Hareketli Ortalama Hesaplama Adımları

Örneğin, 3 periyotluk (n=3) hareketli ortalama hesaplayalım:

Zaman	Veri	MA(3)
1	10	NaN
2	15	NaN
3	12	$(10+15+12)/3 = 12.33$
4	14	$(15+12+14)/3 = 13.67$
5	18	$(12+14+18)/3 = 14.67$

- İlk iki satırda NaN oluşmasının sebebi, pencere boyutunun henüz tamamlanmamış olmasıdır.
- Her yeni satırda, en eski değer çıkartılır ve en yeni değer eklenerek ortalama hesaplanır.

Kod Parçası (Pandas)

python

```
import pandas as pd

s = pd.Series([10, 12, 11, 13, 15, 14, 16])

ma3 = s.rolling(window=3).mean()
print(ma3)
```

Bölmeleme (Binning) Yöntemi

- Bölmeleme (Binning), veriyi belirli aralıklara bölerek **gürültüyü azaltmak ve değişkenliği kontrol etmek** için kullanılan bir yöntemdir. **Veri analizinde ve istatistiksel modellemede yaygın olarak kullanılır.**
- Bölmeleme yöntemi, **devamlı (sürekli) verileri** kategorilere ayırarak **aşırı uç noktaları düzenler, veriyi gruplar ve daha anlamlı hale getirir.**

Bölmeleme (Binning) Formülü ve Çalışma Prensibi

Bölmeleme, veriyi belirli sayıda aralığa böler. Genel olarak iki yöntem vardır:

1. Eşit Genişlik Bölmeleme (Equal Width Binning)

- Veriyi eşit uzunluktaki aralıklara böler.
- Aralık genişliği (w) aşağıdaki formüle göre hesaplanır:

$$w = \frac{\max(X) - \min(X)}{\text{Bin Sayısı}}$$

- Örneğin, 0 ile 100 arasında değişen bir veri kümesi 5 aralığa bölünürse:
 - 0-20 → Bin 0
 - 20-40 → Bin 1
 - 40-60 → Bin 2
 - 60-80 → Bin 3
 - 80-100 → Bin 4

Bölmeleme (Binning) Formülü ve Çalışma Prensibi

■ 2. Eşit Frekans Bölmeleme (Equal Frequency Binning)

- *Her aralıkta (bin) yaklaşık olarak eşit sayıda veri bulunur.*
- *Örneğin, bir veri setinde 100 gözlem varsa ve 5 bin belirlenirse, **her bin yaklaşık 20 veri içerecektir.***
- *Özellikle **dağılımı normal olmayan veri setlerinde** daha iyi sonuç verir.*

Örnek Veri: 1,2,3,4,5,6,7,8,100

① Equal-Width (Eşit Aralıklı)

Adım 1: Min – Max

$min = 1$

$max = 100$

Adım 2: Aralık Genişliği

$(100 - 1)/3 = 99/3 = 33$

Adım 3: Aralıklar

1 – 34

34 – 67

67 – 100

② Equal-Frequency (Eşit Frekanslı)

Toplam 9 veri → 3 bin → her binde 3 veri.

Sıralı veri zaten:

1,2,3,4,5,6,7,8,100

Net Karşılaştırma

Özellik	Equal-Width	Equal-Frequency
Aykırı değerden etkilenme	Çok	Daha az
Boş bin riski	Var	Yok
Veri dağılım dengesi	Bozulabilir	Dengeli
Aralık genişliği	Sabit	Değişken





Eğri Uydurma (Curve Fitting)

- Eğri uydurma, bir veri setine en iyi şekilde uyan matematiksel bir fonksiyon bulma işlemidir. Verinin genel eğilimini modelleyerek, eksik verileri tahmin etmek, gürültüyü azaltmak veya trend analizi yapmak için kullanılır.

Yöntem	Tanım	Kullanım Alanı
Lineer Regresyon (Linear Fit)	Veriye doğrusal bir çizgi uydurur.	Zaman serisi analizi, finansal tahminleme
Polinom Regresyon (Polynomial Fit)	Veriye polinom fonksiyonu uydurur.	İleri seviye trend modelleme, fiziksel deneyler
Spline Interpolasyonu	Veriyi birden fazla parçaya bölerek eğri çizer.	Makine öğrenmesi, tıbbi veri analizi
Gaussian Fit	Veriyi Gauss (normal dağılım) eğrisine oturtur.	Doğal olayların modellenmesi, biyolojik analizler

Hangi Durumda Hangi Yöntem Kullanılır?

Durum	Önerilen Yöntem
Veri doğrusal bir trend izliyorsa	Lineer Regresyon
Veri eğimli ve dalgalı ise	Polinom Regresyon
Veri çok değişkenlik gösteriyorsa	Spline Interpolasyonu
Doğal dağılımı modellemek gerekiyorsa	Gaussian Fit



- Veri temizleme
- Veri birleştirme
- Veri dönüşümü

Veri Birleştirme (Merging & Concatenation)

- Veri birleştirme, **farklı veri setlerini tek bir veri seti haline getirmek** için kullanılan bir işlemdir. Büyük veri analizlerinde ve makine öğrenmesi projelerinde sıkça kullanılan bu teknik, **veri kaynaklarını entegre etmek, eksik verileri tamamlamak ve daha geniş bir analiz yapmak** için gereklidir.

Veri Birleřtirme Yöntemleri ve Kullanım Alanları

Yöntem	Tanım	Kullanım Alanı
<code>concat()</code>	Satırları veya sütunları birleřtirerek veri setini genişletir.	Aynı veri yapısına sahip farklı kaynakları birleřtirme
<code>merge()</code>	Ortak sütuna göre veri setlerini birleřtirir.	İki farklı veri kaynağını entegre etme (örn: müşteri bilgileri & sipariř bilgileri)

1 INNER JOIN (Kesişim)

Sadece iki tabloda da bulunan öğrenciler gelir.

OgrID	Ad	Bölüm
1	Ahmet	Bilgisayar
2	Ayşe	Elektrik
3	Mehmet	Makine
4	Elif	Bilgisayar

OgrID	Vize	Final
1	70	80
2	60	75
4	90	85
5	50	65

OgrID	Ad	Bölüm	Vize	Final
1	Ahmet	Bilgisayar	70	80
2	Ayşe	Elektrik	60	75
4	Elif	Bilgisayar	90	85

2 LEFT JOIN

Sol tablo (Öğrenci tablosu) korunur.

OgrID	Ad	Bölüm
1	Ahmet	Bilgisayar
2	Ayşe	Elektrik
3	Mehmet	Makine
4	Elif	Bilgisayar

OgrID	Vize	Final
1	70	80
2	60	75
4	90	85
5	50	65

OgrID	Ad	Bölüm	Vize	Final
1	Ahmet	Bilgisayar	70	80
2	Ayşe	Elektrik	60	75
3	Mehmet	Makine	NaN	NaN
4	Elif	Bilgisayar	90	85

3 RIGHT JOIN

Sağ tablo korunur.

OgrID	Ad	Bölüm
1	Ahmet	Bilgisayar
2	Ayşe	Elektrik
3	Mehmet	Makine
4	Elif	Bilgisayar

OgrID	Vize	Final
1	70	80
2	60	75
4	90	85
5	50	65

OgrID	Ad	Bölüm	Vize	Final
1	Ahmet	Bilgisayar	70	80
2	Ayşe	Elektrik	60	75
4	Elif	Bilgisayar	90	85
5	NaN	NaN	50	65

4 FULL OUTER JOIN Sağ tablo korunur.
Tüm kayıtlar korunur.

OgrID	Ad	Bölüm
1	Ahmet	Bilgisayar
2	Ayşe	Elektrik
3	Mehmet	Makine
4	Elif	Bilgisayar

OgrID	Vize	Final
1	70	80
2	60	75
4	90	85
5	50	65

OgrID	Ad	Bölüm	Vize	Final
1	Ahmet	Bilgisayar	70	80
2	Ayşe	Elektrik	60	75
3	Mehmet	Makine	NaN	NaN
4	Elif	Bilgisayar	90	85
5	NaN	NaN	50	65

Gereksiz Veri

- Bu veri kümesi, farklı kaynaklardan elde edilen tabloların birleştirilmesi sonucu oluşmuş ve bu süreçte gereksiz, tekrarlı veya eksik kayıtlar içerebilir.

Durum	Çözüm
Eksik hedef değişken	Sil
Eksik bağımsız değişken	Doldur
Tutarsız eşleşme	Sil
Tekrar eden kayıt	Temizle

Hangi sıralama?

Temizleme?

Birleştirme?

Hangi sıralama?

■ Doğru Veri Akışı (Profesyonel Pipeline)

- 1 Ham veri al
- 2 İlk temizlik (tip kontrol, anahtar kontrol)
- 3 Birleştir
- 4 İkinci temizlik (NaN, duplicate, mantık kontrol)
- 5 Özellik mühendisliği
- 6 Modelleme

- Veri temizleme
- Veri birleştirme
- Veri dönüşümü

Veri Dönüşümü (Data Transformation)

- **Veri dönüşümü**, verilerin analize daha uygun hale getirilmesi için kullanılan bir süreçtir. Ham veriyi düzenlemek, ölçeklendirmek veya belirli bir formata sokmak amacıyla uygulanır.

- **Veri Dönüşümünün Önemi**

- ✓ Farklı veri türlerini standart hale getirmek
- ✓ Makine öğrenmesi ve istatistiksel analizler için uyumluluk sağlamak
- ✓ Ölçek farklılıklarını azaltmak ve model performansını artırmak
- ✓ Aykırı değerlerin etkisini azaltmak

Veri Dönüşüm Teknikleri

■ Normalizasyon (Min-Max Scaling)

- *Tanım:*
- *Verileri belirli bir aralığa (genellikle 0-1) ölçeklendirerek, değişkenler arasındaki büyük ölçek farklarını ortadan kaldırır.*
- *Formül:*

$$X_{scaled} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

Veri Dönüşüm Teknikleri

Standartlaştırma (Z-Score)

- Verileri ortalaması **0**, standart sapması **1** olacak şekilde dönüştürür.

– *Formül:*

$$Z = \frac{X - \mu}{\sigma}$$

Logaritmik Dönüşüm

- Çok büyük değerleri küçültmek ve çarpıklığı (skewness) azaltmak için kullanılır.

– *Formül:*

$$X_{log} = \log(X)$$

Kategorik Verileri Sayısal Hale Getirme (Encoding)

One-Hot Encoding

- Kategorileri 0-1 formatına dönüştürme

Label Encoding

- Kategorileri sayısal hale getirme

Teknik	Amaç
Normalizasyon	Ölçek eşitleme
Standartlaştırma	Ortalama 0, std 1
Log	Çarpıklığı azaltma
Binning	Sürekli → kategorik
One-Hot	Kategorik → vektör
Label Encoding	Kategorik → sayısal

Tüm Dönüşümler Aynı Tabloda

ID	Yaş	Gelir	Bölüm
1	18	1000	Bilgisayar
2	25	2000	Elektrik
3	40	3000	Makine
4	60	5000	Bilgisayar

Tüm Dönüşümler Aynı Tabloda

ID	Yaş	Yaş_Grup (Binning)	Gelir	Gelir MinMax	Gelir Zscore	Gelir Log	Bölüm	Label	Bilgisayar	Elektrik	Makine
1	18	Genç	1000	0.00	-1.14	6.90	Bilgisayar	0	1	0	0
2	25	Genç	2000	0.25	-0.38	7.60	Elektrik	1	0	1	0
3	40	Orta	3000	0.50	0.38	8.01	Makine	2	0	0	1
4	60	İleri	5000	1.00	1.14	8.52	Bilgisayar	0	1	0	0

BITTI 😊