

EDA Nedir?

Dr.Öğr.Üyesi Günay TEMÜR

EDA Nedir?

- EDA Açılımı:
 - Exploratory Data Analysis
- Türkçesi:
 - Keşifsel Veri Analizi

EDA'nın Anlamı Nedir?

- EDA, veri setini model kurmadan önce:
 - Tanımak
 - Anlamak
 - Problemleri görmek
 - Yapısını çözmek
- amacıyla yapılan analiz sürecidir.

Akademik Tanım

- Exploratory Data Analysis is the process of examining, visualizing and summarizing data in order to discover patterns, detect anomalies, test assumptions, and check data quality before modeling.

EDA Neden Yapılır?

- Model kurmadan önce şu sorulara cevap ararız:
 - Veri kaç satır?
 - Eksik değer var mı?
 - Outlier var mı?
 - Dağılım normal mi?
 - Sınıf dengesi var mı?
 - Değişkenler arasında ilişki var mı?

EDA'nın Amaçları

- **1** Veri kalitesini kontrol etmek
- 2** Veri temizleme ihtiyacını belirlemek
- 3** Özellik seçimine karar vermek
- 4** Model tipini tahmin etmek
- 5** Varsayımları test etmek

EDA Türleri

- ◆ **Univariate Analysis**

- Tek değişken analizi (Histogram, Boxplot)

- ◆ **Bivariate Analysis**

- İki değişken arası ilişki (Scatter, Korelasyon)

- ◆ **Multivariate Analysis**

- Çoklu değişken analizi (Heatmap, Pairplot)

EDA AKIŞ DİYAGRAMI

- **1 Veri Yükleme**
 - Dosya okuma
 - İlk 5 satır
 - Boyut kontrolü

Veri geldi mi? Kaç satır? Kaç sütun?

EDA AKIŞ DİYAGRAMI

- **2** Veri Yapısını Anlama
 - Sütun tipleri
 - Sayısal / Kategorik ayrımı
 - Hedef değişken belirleme

Bu veri ne tür bir problem?

Sınıflandırma mı? Regresyon mu?

EDA AKIŞ DİYAGRAMI

- **3** Veri Kalitesi Kontrolü
 - Eksik değer
 - Yanlış veri tipi
 - Tutarsız değer
 - Duplicate kayıt

Temiz mi? Müdahale gerekiyor mu?

EDA AKIŞ DİYAGRAMI

- **4 Tek Değişken Analizi (Univariate)**
 - Histogram
 - Boxplot
 - Countplot

Dağılım nasıl?

Outlier var mı?

Çarpıklık var mı?

EDA AKIŞ DİYAGRAMI

- **5 İki Değişken Analizi (Bivariate)**
 - Korelasyon
 - Scatter plot
 - Kategori vs target

İlişki var mı?

Hangi feature güçlü?


EDA AKIŞ DİYAGRAMI

- **6 Çoklu Analiz (Multivariate)**
 - Heatmap
 - Pairplot
 - Gruplama analizleri

EDA AKIŞ DİYAGRAMI

- **7 Model Öncesi Karar**
 - Dönüşüm gerekli mi?
 - Feature çıkarılmalı mı?
 - Class imbalance var mı?

Akışın Özet Şeması



!!!EDA yapılmadan kurulan model, bilinmeyen bir zemine bina inşa etmeye benzer.

Örnek Uygulama -1

-  Bu Veri Setinde Problem Ne?
 - Bank Marketing veri setinde hedef değişken:
 $y = \text{yes} / \text{no}$
- Bu ne demek?
 -  İkili sınıflandırma (Binary Classification)
- Amaç:
 - Bir müşterinin vadeli mevduata abone olup olmayacağını tahmin etmek.
-  Bundan Sonraki Aşama: Modelleme

Örnek

Uygulama -2

Univariate

Analiz

- **Bu adımda ne yaptık?**
- Target (income) dağılımını inceledik.
- Age dağılımını histogram ile analiz ettik.
- Hours_per_week dağılımını inceledik.
- Capital_gain'in aşırı çarpık olduğunu gördük.
- **Amaç neydi?**
- Veri dengesini görmek
- Çarpıklık (skewness) tespiti
- Outlier var mı görmek
- Dönüşüm gereksinimi olup olmadığını anlamak
- **Önemli Bulgular**
- Veri dengesiz (%76 düşük gelir)
- Capital_gain aşırı sağa çarpık
- Hours_per_week 40 saat yoğunlukta
- Age normal dağılıma yakın

Örnek

Uygulama -2

Bivariate Analiz

- **Bu adımda ne yaptık?**
- Age vs Income boxplot
- Hours_per_week vs Income boxplot
- Education vs Income oran analizi
- **Amaç neydi?**
- Hedef değişken ile ilişkili feature var mı görmek
- Ayırıştırıcı değişkenleri tespit etmek
- **Önemli Bulgular**
- Yüksek gelir grubunun yaşı daha yüksek
- Yüksek gelir grubunun çalışma süresi daha fazla
- Eğitim seviyesi arttıkça >50K oranı artıyor
- Bu aşamada şunu gördük:
- Bu veri setinde anlamlı ayırt edici değişkenler mevcut.

Örnek

Uygulama -2

Multivariate Analiz

- **Bu adımda ne yaptık?**
- Sayısal değişkenler arasında korelasyon matrisi
- Pairplot ile çoklu dağılım analizi
- **Amaç neydi?**
- Özellikler arasında multicollinearity var mı?
- Güçlü korelasyon var mı?
- **Bulgular**
- Sayısal değişkenler arasında aşırı yüksek korelasyon yok
- education_num gelirle güçlü ilişkili
- capital_gain log dönüşüm gerektiriyor

MODEL ÖNCESİ KARAR AŞAMASI

- **Bu adımda ne yaptık?**
- Duplicate kayıt kontrolü
- "?" gibi gizli eksik değer kontrolü
- Log dönüşüm önerisi
- Target encode
- Education vs binary education_num redundans kontrolü
- **Amaç neydi?**
- Model kurmadan önce:
- Veri temiz mi?
- Dönüşüm gerekiyor mu?
- Hangi sütunlar çıkarılmalı?
- Class imbalance var mı?
- Bu aşama = Model hazırlık safhası.


BANK vs ADULT KARŞILAŞTIR MATABLOSU

Özellik	Bank Marketing	Adult Income
Satır Sayısı	45.211	32.561
Sütun Sayısı	17	15
Problem Türü	Binary Classification	Binary Classification
Leakage Riski	Var (duration)	Yok
Class Imbalance	Çok Yüksek (~12%)	Orta (~24%)
Outlier	Aşırı (balance)	Orta (capital_gain)
Temizlik	Karmaşık	Daha Stabil
Gerçek Dünya Zorluğu	Yüksek	Orta
Öğretim Kolaylığı	Orta	Yüksek
Dönüşüm Gereksinimi	Fazla	Orta
Feature Redundancy	Az	Var (education vs education_num)

Sonuç

- **Bank Dataset:**
- Gerçek dünya karmaşası
 - Outlier
 - Leakage
 - Dengesizlik
 - Özel kodlar
- **Adult Dataset:**
- Daha temiz
 - Daha stabil
 - Model öğretmek için ideal

Modelleme





Kurulabilecek Modeller

- Bu veri seti için uygun modeller:
- **1 Logistic Regression**
 - Basit
 - Yorumlanabilir
 - Akademik olarak temel model
- **2 Decision Tree**
 - Outlier'a dayanıklı
 - Görsel açıklanabilir
- **3 Random Forest**
 - Daha güçlü
 - Feature importance verir
- **4 XGBoost / Gradient Boosting**
 - Daha ileri seviye

BİTTİ ☺