

VERİ MADENCİLİĞİ

Dr.Öğr.Üyesi Günay TEMÜR

VERİ MADENCİLİĞİ ALGORİTMALARI

Büyük veri setlerinden anlamlı bilgi keşfetme yöntemleri



VERİ ANALİZİ & BİLGİ KEŞFİ

TAHMİN

- Gelir Tahmini
- Müşteri Riski

DESEN KEŞFİ


- Segmentler
- Kurallar

KURAL MADENCİLİĞİ

- Sepet Analizi
- Tavsiye Sistemleri

MAKİNE ÖĞRENMESİ: PROBLEM TÜRLERİ & ALGORİTMALAR

Denetimli ve denetimsiz öğrenmenin algoritmik haritası



Makine Öğrenmesi

- Makine öğrenmesi (Machine Learning), bilgisayar sistemlerinin **açıkça programlanmadan verilerden öğrenmesini sağlayan yöntemler bütünüdür.**
 - Makine öğrenmesinin amacı:
 - Verilerdeki **örüntüleri (patterns)** keşfetmek
 - Gelecekteki durumları **tahmin etmek**
 - Veriler arasındaki **ilişkileri öğrenmek**

Makine Öğrenmesi Türleri

- Makine öğrenmesi genel olarak üç ana kategoriye ayrılır:
 - Denetimli Öğrenme (Supervised Learning)
 - Denetimsiz Öğrenme (Unsupervised Learning)
 - Pekiştirmeli Öğrenme (Reinforcement Learning)
- Veri madenciliği derslerinde genellikle ilk iki kategori incelenir.

Denetimli Öğrenme (Supervised Learning)

Denetimli öğrenme, **girdi verileri ile birlikte doğru sonuçların (etiketlerin) bulunduğu veri setleri ile modelin eğitilmesi sürecidir.**

Model:

- giriş verilerini (features)
- hedef değişkeni (label)

kullanarak öğrenir.

Amaç:

- Yeni gelen veriler için doğru tahmini yapabilen bir model geliştirmektir.

Age	Balance	Loan	Sonuç
35	2000	No	Yes
28	100	Yes	No
42	5000	No	Yes

Denetimsiz Öğrenme (Unsupervised Learning)

- Denetimsiz öğrenme, **etiket bilgisi bulunmayan veri setleri üzerinde gerçekleştirilen öğrenme sürecidir.**
- Model yalnızca verinin kendisini analiz ederek **veri içerisindeki yapıyı keşfetmeye çalışır.**
- Amaç:
 - veri gruplarını keşfetmek
 - ilişkileri ortaya çıkarmak
 - veri içindeki desenleri bulmak

Decision Tree → Random Forest

- Decision Tree (Karar Ağaçları), veriyi **ardışık kararlar vererek bölme mantığı ile çalışan bir sınıflandırma algoritmasıdır.**
- Karmaşık veri setlerinde kullanılabilir.
- Model veri setini şu şekilde bölerek ilerler:

Yaş > 40 ?


/ \
evet hayır

Her düğüm:

- bir özellik
- bir karar kuralı

temsil eder.

Karar Ağaçları



Karar Ağaçları

- Karar ağaçlarının ilk hücrelerine **kök** (root veya root node) denir. Her bir gözlem kökteki koşula göre “Evet” veya “Hayır” olarak sınıflandırılır.
- Kök hücrelerinin altında **düğüm**ler (interval nodes veya nodes) bulunur. Her bir gözlem düğümler yardımıyla sınıflandırılır. Düğüm sayısı arttıkça modelin karmaşıklığı da artar.
- Karar ağacının en altında **yapraklar** (leaf nodes veya leaves) bulunur. Yapraklar, bize sonucu verir.

Karar Ağaçları

Decision Tree Avantajları

- yorumlanması kolaydır
- görselleştirilebilir
- veri hakkında sezgisel bilgi sağlar

Decision Tree Dezavantajı


Karar ağaçlarının en önemli problemi:

- **Overfitting**

Yani model:

- Eğitim verisini fazla öğrenerek yeni verilerde kötü performans gösterebilir.
- Bu problemi azaltmak için geliştirilmiş yöntemlerden biri **Random Forest** algoritmasıdır.

Karar Ağaçları



Peki ya kök hücreyi nasıl seçiyoruz?

- Burada seçeceğimiz kökün veri setimizi olabildiğince çok açıklamasını isteriz. Örneğin örnek karar ağacına bakarsak, bu kişi için iş teklifinde en önemli etken maaşmış.
- Köke tabi ki biz karar vermiyoruz. Buna karar vermek için çeşitli değerler var. Bunlardan bazıları:

Karar Ağacında Kök Düğüm Nasıl Seçilir?

- Bir veri setinde çok sayıda özellik (feature) bulunabilir.
- Örnek veri seti:

Age	Balance	Loan	Duration	Job	Outcome
35	2000	No	120	admin	Yes
28	100	Yes	80	student	No
42	5000	No	200	manager	Yes

Decision Tree'de Bölme Kriterleri

- Karar ağaçları veri setini bölerek sınıflandırma yapar. Ancak her bölme işlemi için **en uygun özelliğin seçilmesi gerekir.**
- Bu seçim yapılırken veri setindeki **safılık (purity)** ölçülür.
- Safılık ölçümü için en yaygın kullanılan iki yöntem:
 - Entropy
 - Gini Index
- Bu ölçüler, veri setindeki **karışıklık (impurity)** seviyesini hesaplar.

Karar Ağacında Kök Düğüm Nasıl Seçilir?

Algoritma şu adımları izler:

1. Veri setinin başlangıç düzensizliği hesaplanır
2. Her özellik için veri ikiye veya daha fazla gruba bölünür
3. Her bölme için saflık ölçülür
4. En fazla saflık artışı sağlayan özellik seçilir

Yani algoritma:

- “Hangi özellik sınıfları en iyi ayırıyor?” sorusunu cevaplar.

Bu özellik **kök düğüm (root node)** olur.

Entropy (Bilgi Kazancı Yaklaşımı)

Entropy, veri setindeki **belirsizlik veya düzensizlik miktarını ölçer**.

Entropy değeri:

- **0** → **tamamen saf veri**
- **1** → **tamamen karışık veri**

Entropy formülü:

$$Entropy(S) = - \sum p_i \log_2(p_i)$$

Burada:

- p_i → her sınıfın olasılığıdır.

Kök Seçimi

Varsayalım veri setinde üç özellik var:

- Age
- Balance
- Loan

Algoritma üç ayrı bölme dener:

- Age ile böl
- Balance ile böl
- Loan ile böl

Her bölme için **Gini veya Entropy** hesaplanır.

En iyi sonuç veren özellik seçilir.

Örnek sonuç:

Özellik	Saflık
Age	0.42
Balance	0.31
Loan	0.12

En düşük düzensizlik:

👉 **Loan**

Bu nedenle kök düğüm:

Loan ?

Alt Düğümler Nasıl Oluşur?

Kök düğüm seçildikten sonra:

Veri iki gruba ayrılır.

- Loan = Yes
- Loan = No


Her grup için algoritma **aynı işlemi tekrar yapar.**

Yani tekrar sorulur:

Bu alt veri setinde en iyi ayıran özellik hangisi?

Bu işlem şu ana kadar devam eder:

- veri tamamen saf olana kadar
veya
- durdurma kriteri sağlanana kadar.



Information Gain (Bilgi Kazancı)

Decision Tree algoritması her bölme işleminde şu soruyu sorar:

Bu bölme veri setindeki belirsizliği ne kadar azaltıyor?

Bu azalmaya **Information Gain** denir.

Formül:

$$Gain = Entropy(parent) - Entropy(children)$$

En yüksek bilgi kazancı sağlayan özellik seçilir.

Gini Index de veri setinin **saflık ölçüsüdür**.

- Formül:

$$Gini = 1 - \sum p_i^2$$

Özellikleri:

- 0 → tamamen saf
- yüksek değer → karışık veri

Decision Tree algoritması **Gini değerini azaltmaya çalışır**.

Hangisi Kullanılır?

Karar ağacı algoritmaları:

- **Entropy kullanabilir**
- **Gini kullanabilir**

Yani bu bir **seçimdir**.

Örneğin:

Scikit-learn kütüphanesinde:

- `criterion="gini"`
`criterion="entropy"`

şeklinde seçim yapılabilir.

Varsayılan:

- 👉 **Gini Index**

Karar ağacı algoritması:

1. Her özellik için bölme dener
2. Gini veya Entropy hesaplar
3. En iyi bölmeyi seçer
4. Alt ağaçları oluşturur
5. İşlem yaprak düğüme kadar devam eder

Amaç:

- Veriyi en saf şekilde ayıran karar yapısını oluşturmak.

Makine Öğrenmesi Eğitim Süreci

1 Veri Seti (Dataset)

Age	Education	Hours_per_week	Capital_gain	Income
39	Bachelors	40	2174	<=50K
50	Bachelors	13	0	<=50K
38	HS-grad	40	0	<=50K

Burada:

- her **satır** → bir gözlem (record)
- her **sütun** → bir özellik (feature)

Makine Öğrenmesi Eğitim Süreci


2 X ve Y Ayrımı

Makine öğrenmesi modeline veri verirken önce veri iki parçaya ayrılır.

X → Girdi Değişkenleri (Features)

Modelin karar verirken kullandığı değişkenlerdir.

- Örnek:
- Age
Education
Hours_per_week
Capital_gain



Y → Hedef Değişken (Target / Label)

Modelin tahmin etmek istediği değişkendir.

- Income

Yani:

X → modelin baktığı bilgiler

Y → modelin tahmin edeceği sonuç

Makine Öğrenmesi Eğitim Süreci

3 Eğitim ve Test Verisi Ayrımı

Modelin gerçek öğrenme yapabilmesi için veri ikiye ayrılır.

Eğitim Verisi (Training Set)

Model bu veri üzerinde öğrenir.

verinin yaklaşık %70-80'i


Test Verisi (Test Set)

Modelin ne kadar doğru öğrendiğini ölçmek için kullanılır.

verinin yaklaşık %20-30'u

Amaç:

Modeli hiç görmediği veri üzerinde test etmek.



Makine Öğrenmesi Eğitim Süreci

4 Model Eğitimi (Training)

Bu aşamada makine öğrenmesi algoritması veriyi analiz ederek **bir model oluşturur**.

Örneğin Decision Tree:

- Age > 35 ?
 - Yes → Income > 50K
 - No → Income ≤ 50K

Model veri içindeki **örüntüleri (patterns)** öğrenir.

5 Tahmin (Prediction)

Eğitilmiş model artık yeni veri için tahmin yapabilir.

Örnek:

Age	Education	Hours_per_week
45	Masters	50

Model çıktısı: Income > 50K

Makine Öğrenmesi Eğitim Süreci

6 Model Değerlendirme (Evaluation)

Modelin başarısı ölçülür.

En yaygın ölçütler:


- Accuracy
- Precision
- Recall
- F1 Score
- Confusion Matrix

Amaç:

Model gerçekten öğrenmiş mi yoksa ezber mi yapmış?

7

Machine Learning Pipeline: From Data to Deployment



BİTTİ 😊

Dönem Sonu Çalışması

Çalışma Konusu

- 1 en az 50.000 gözlem içeren bir veri seti bulunacak.
- 2 ders içinde verilen uygulama kodları kullanılarak model çalıştırılacak.
- 3 ilk aşamada **kodlarda hiçbir değişiklik yapılmadan model eğitilecek.**
- 4 ikinci aşamada model üzerinde değişiklikler yapılarak model performansı artırılmaya çalışılacaktır.

Algoritmalar Hoca tarafından **10. Hafta** sonunda **rastgele dağıtılacaktır.**
Teslim **14. Haftada** gerçekleştirilecektir.

Dönem Sonu Çalışması

Temel Model Eğitimi

Derste verilen uygulama kodları **hiç değiştirilmeden** çalıştırılacaktır.

Bu aşamada:

- X – Y ayrımı
- Train – Test ayrımı
- Model eğitimi
- Model değerlendirme

yapılacaktır.

Elde edilen sonuçlar raporlanacaktır.

Model İyileştirme

Amaç:

Model başarımını artırmak.

Örnek iyileştirmeler:

- train/test oranı değiştirme
- model derinliği değiştirme
- parametre ayarları
- veri temizleme
- özellik seçimi
- veri dönüşümü

Dönem Sonu Çalışması

Sonuçların Karşılaştırılması

Öğrenciler şu iki sonucu karşılaştıracaktır:

Model Türü	Accuracy
İlk Model	?
Geliştirilmiş Model	?
Başarılı Model	?

Değerlendirme Ölçütleri

Kriter	Puan
Veri setine hakimiyet	20
Veri analizi	10
Modele hakimiyet	30
Model iyileştirme	30
Başarılı Sonuç	10

Toplam: 100 puan

 **Dönem Sonu Genel Değerlendirme Ölçütleri**
=
Vize (%35) + Çalışma (%15) + Final (%50)

BİTTİ 😊